




Línea continua: pertenece a la rama | Línea roja punteada: relación entre conceptos

Fichas de conceptos del mapa mental

Fundamentos

Concepto	¿Qué es?	¿Para qué sirve?	Ejemplo	Uso en el laboratorio
Inteligencia Artificial	Campo que busca que las máquinas realicen tareas que requieren inteligencia	Automatizar decisiones, percepción y lenguaje	Asistentes, recomendadores	Marco general del laboratorio
Machine Learning	Subcampo de la IA que aprende patrones a partir de datos	Predecir/clasificar sin reglas escritas a mano	Regresión lineal, árboles	Modelo predictivo (Comp. 4)
Deep Learning	ML con redes neuronales de muchas capas	Procesar texto, imagen, audio	Reconocimiento de voz	Base de los modelos ejecutados
Redes neuronales	Capas de neuronas con pesos ajustables	Aprender relaciones no lineales	Perceptrón multicapa	Explica qué son los parámetros
Transformers	Arquitectura basada en atención (2017)	Procesar secuencias largas en paralelo	GPT, Llama, BERT	Arquitectura de los LLM (Comp. 2)
Modelos fundacionales	Modelos grandes preentrenados, adaptables a muchas tareas	Reutilizar sin entrenar desde cero	Llama, GPT, Claude	Comp. 1 a 3

Tipos de modelos

Concepto	¿Qué es?	¿Para qué sirve?	Ejemplo	Uso en el laboratorio
LLM	Modelo de lenguaje grande	Generar y entender texto	GPT-4o, Llama 3 70B	Modelo generalista (Comp. 2 y 3)
SLM	Modelo de lenguaje pequeño y eficiente	Correr en equipos modestos	Phi-3, Llama 3.2 3B	Opción según hardware
VLM	Modelo de visión y lenguaje	Analizar imágenes con texto	LLaVA, Qwen-VL	Cartografía (Comp. 1)
Modelos de código	LLM especializados en programación	Generar, explicar y corregir código	Qwen2.5-Coder, CodeLlama	Local coding (Comp. 2 y 3)
Multimodales	Combinan texto, imagen, audio, video	Tareas mixtas	GPT-4o, Gemini	Cartografía
Embeddings	Convierten texto en vectores	Búsqueda semántica, similitud	nomic-embed-text	Cartografía
Speech-to-Text	Voz a texto	Transcripción	Whisper	Cartografía (voz)
Text-to-Speech	Texto a voz	Narración, accesibilidad	Piper, ElevenLabs	Cartografía (voz)

Funcionamiento

Concepto	¿Qué es?	¿Para qué sirve?	Ejemplo	Uso en el laboratorio
Parámetros	Pesos aprendidos; indican el tamaño	Más parámetros: más capacidad y memoria	7B = 7 mil millones	Elegir modelo según hardware
Tokens	Fragmentos de texto que procesa el modelo	Medir entrada, salida y costo	"programación" = 2-3 tokens	Costos y velocidad (tokens/s)
Ventana de contexto	Máximo de tokens visibles a la vez	Limita largo de prompts/código	8K, 128K	Columna Contexto (Comp. 1)
Inferencia	Usar un modelo ya entrenado	Obtener respuestas	Consultar Llama en Ollama	Comp. 2 y 3
Temperatura	Controla la aleatoriedad	Baja = precisa; alta = creativa	0.2 código, 0.8 ideas	Script Python (Comp. 2)
Cuantización	Reducir precisión de los pesos (16 a 4/8 bits)	Menos RAM/VRAM	Q4_K_M, GGUF	Registro técnico (Comp. 2)

Entrenamiento vs inferencia	Entrenar ajusta pesos; inferir los usa	Saber qué es viable localmente	Entrenar Llama: miles de GPU; usarlo: un portátil	Inferencia en Comp. 2-3; entrenamiento simple en Comp. 4
-----------------------------	--	--------------------------------	---	--

Formas de uso

Concepto	¿Qué es?	¿Para qué sirve?	Ejemplo	Uso en el laboratorio
Modelo local	Se ejecuta en el propio equipo	Privacidad, sin costo por uso, offline	Llama en Ollama	Comp. 2
Modelo cloud	Se ejecuta en servidores del proveedor	Potencia sin hardware propio	GPT, Claude, Codex	Cloud coding (Comp. 3)
API	Interfaz programa-modelo	Integrar IA en aplicaciones	localhost:11434	Script Python (Comp. 2)
Interfaz de chat	Aplicación conversacional	Uso interactivo	ChatGPT, chat de LM Studio	Pruebas manuales
Open-weight	Pesos descargables	Ejecutar y adaptar localmente	Llama, Qwen, Mistral	Modelos locales
Propietario	Pesos cerrados, acceso por API/app	Modelos de frontera	GPT-4o, Claude	Comparación (Comp. 3)

Infraestructura

Concepto	¿Qué es?	¿Para qué sirve?	Ejemplo	Uso en el laboratorio
CPU	Procesador general	Ejecutar modelos pequeños (lento)	Intel i5, Ryzen 5	Plan B sin GPU
GPU	Procesador paralelo	Acelerar la inferencia	NVIDIA RTX, Apple M	Rendimiento (Comp. 2)
RAM	Memoria del sistema	Cargar el modelo en CPU	16 GB ≈ 7B en Q4	Registro de recursos
VRAM	Memoria de la GPU	Cargar el modelo en GPU	8 GB	Registro de recursos
Ollama	Runtime/servidor local por CLI	Descargar, ejecutar, exponer API	ollama run llama3.2	Comp. 2
LM Studio	App gráfica con servidor compatible OpenAI	Probar modelos y exponer API	localhost:1234	Comp. 2
Servicios cloud	Plataformas que alojan modelos	Acceso a modelos grandes por API	OpenAI, Anthropic, Google	Comp. 3